# F74072251 資訊系 111 級 蔡哲平 作業系統 作業一

## 開發環境:

(1) OS: Windows 10 家用版

(2) CPU: intel(R) Core(TM) i7-8750H CPU@ 2.20GHz 2.20GHz

(3) Memory: 8.00GB (7.85GB 可用)

(4) Programming Language(version): C++11

## 程式執行時間:

因在 windows 環境下跑 1G 的測資會跑非常久,故在測試各 thread 時間時只有使用 100MB 的測資,但在 ubuntu 就有使用 1G 的測資因為滿快,可以看到在 windows 下 100MB 花的時間甚至比 ubuntu 下 1G 還久。

1	Win10	100MB	Linux	1GB
2	thread	time	thread	time
3	1	33.13	1	50.458
4	2	33.778	2	49.7426
5	4	50.256	4	50.1435
6	8	63.107	8	50.5733
7	16	65.617	16	51.5822
8	32	75.636	32	50.3857
9	64	83.029	64	50.5385
10	128	80.82	128	50.6083
11	256	80.209	256	50.476
12	512	82.788	512	50.3132
13	1024	78.707	1024	50.8169
14	2048	76.163	2048	51.1432

## 程式開發與使用說明:

#### (1) 程式開發過程:

這份程式我更改了許多次,不斷嘗試不同方法,光是轉換成 json 格式的函式我就寫了五個版本,最後是使用下面這個,因為速度最快

```
void convertStr(string& inputStr, bool last = false) {
          string resultStr = "\t{\n\t\t\col 1\":";
10
          int findSplit = inputStr.find("|");
12
         while(findSplit != string::npos) {
              cnt++;
13
              resultStr += (inputStr.substr(0, findSplit) + ",\n\t\t\col_" + to_string(cnt) + "\":");
14
              inputStr = inputStr.substr(findSplit + 1);
15
              findSplit = inputStr.find("|");
16
              resultStr += (inputStr + "\n\t}\n");
20
             resultStr += (inputStr + "\n\t},\n");
21
          inputStr = resultStr;
```

函式傳入 csv 格式字串的 reference·會直接將那個字串改成 json 格式。而我的程式邏輯就是先將 input.csv 讀入且存進一個 vector·再依照使用者輸入的執行緒個數去分配各個執行緒所負責的部分·假設 input.csv 有 100行·總共 5 個執行緒·那第一個執行緒就是負責 inputVec 的第 0 到 19項·其餘以此類推·而各執行緒要負責的就是將字串轉成 json 格式存回 inputVec·最後當所有執行緒都處理完成後再 inputVec 的結果輸出至檔案。第一個版本我很快就寫完,但隨這測試檔案的大小愈大,終於在測試 500M 的時候發生了 std::bad\_alloc·原先我是 input 跟 output 各一個 vector·而這也是導致 memory leak 的原因·所以後來我改成直接將轉好的字串存回 inputVec·但一樣還是爆掉·所以就決定採用作業一的方式, 利用一個 buffer 去處理·當 buffer 滿了就輸出·再繼續讀剩餘之 input。

## (2) 在 Ubuntu 環境下程式使用方法:

程式編譯: g++ ETL.cpp -O3 -o ETL -l pthread

程式執行: ./ETL [thread num]

Buffer 的大小設為 200 萬,也就是一次最多能處理 200 萬行,1G 差不多

是 500 萬行,程式就會自己重複跑三次才能處理完所有測資,執行結果如

#### 下圖

## 效能分析報告:

#### (1) I/O bound or CPU bound?

由上面那張圖可得知,在一次讀檔、資料處理、輸出的過程中,讀檔跟輸出

分別只有大概一秒,而資料處理也就是轉換成 json 格式卻佔用了 18 秒,換句話說,整個過程中 I/O 只佔了約 10%的時間,而資料處理就佔了近 90%,由此可知這次的作業是屬於 CPU bound。下圖是我原先所寫的輸出 函式:

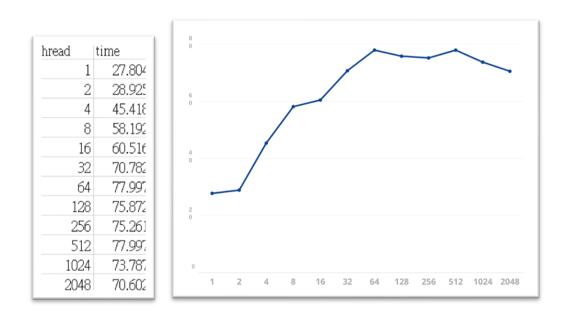
```
8 = void printVec(const vector string>& stringVec, ofstream& fout, bool last = false) {
 9
          int line = 1;
10 |
11 |
           for(int i = 0; i < stringVec.size(); i++) {</pre>
              if(line == 1) {
                   fout << "\t{\n";
12
                   fout << "\t\t\"col_" << line << "\":" << stringVec.at(i) << ",\n";
13
15
16
              else if(line == 20) {
                  fout << "\t\t\"col_" << line << "\":" << stringVec.at(i) << "\n";
17
                   fout << "\t}";
19 = 20 = 21 = =
                  if(i == stringVec.size() - 1 && last) {
                      fout << ",";
23
                   fout << "\n";
24
25
                  line = 1;
26
27
              else {
                  fout << "\t\t\"col_" << line << "\":" << stringVec.at(i) << ",\n";
28
29
                   line++;
30
31
          }
```

可看出我在函式中頻繁的使用 fout,而不是直接輸出一整串轉好的 json 格式至檔案,實測後發現這種寫法會拖慢速度,我的理解是因為這樣會使作業系統頻繁的在 cpu 跟 I/O 之間做切換,但其實可以先利用 cpu 將整串完全轉好成 json 格式,再一次整串輸出至檔案,就可以解決此問題,以下是我的程式碼:

```
int outputStart = clock();
if(!bufferFull)
fout << "[\n";
for(auto& i: inputVec)
fout << i;
int outputEnd = clock();</pre>
```

這樣輸出就是一次一整行,可大幅減少 I/O 時間。

## (2) 不同 thread 數量的比較



上圖是在 windows 環境下測試 100M 的資料處理部分所花的時間,由於檔 案輸入及輸出,在不同 thread 數量時差距很小,故把資料處理的部分拿來 討論,可以發現 thread 個數越多,資料處理的速度反而越來越慢,由下圖 可看到在 1 個執行緒及 2048 個執行緒時 cpu 使用量差異是極大的,

CPU ✓ 影像 PID 描述 狀態 執行緒 CPU 平均 CPU ✓ ETLexe 15068 ETL 終止 8.03 (>) 檢視 CPU 100% 60 秒

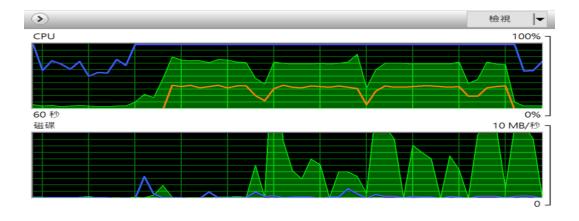
Thread: 1 / CPU: 8%

Thread: 1024 / CPU: 90%up



雖然 1 個執行緒只使用了 8%的 cpu · 但是卻比使用了 90%以上 cpu 的 2048 個執行緒速度快上非常多 · 上網查了一下資料後 · 發現其實各執行緒 是不會同時執行的 · 一顆 CPU 同時只能執行一項任務 · 為了讓使用者感覺 這些任務正在同時進行 · 作業系統的設計者巧妙地利用了時間片輪轉的方式 · CPU 給每個任務都服務一定的時間 · 然後把當前任務的狀態儲存下來 · 在載入下一任務的狀態後 · 繼續服務下一任務。任務的狀態儲存及再載 入 · 這段過程就叫做上下文切換。時間片輪轉的方式使多個任務在同一顆 CPU 上執行變成了可能 · 但同時也帶來了儲存和載入的直接消耗 · 而這也 導致了更多的執行緒不見得會使速度變快。

## (3) CPU 在程式執行中的使用狀況



上圖是我使用 8 個 thread 的程式完整生命週期,這次測試是讀進 50 萬行,buffer 存 15 萬行,所以 cpu 那邊共有三次起伏,可以觀察到在在資料處理的部分 cpu 使用量很高,而因為本次作業資料量不大,所以 I/O 時間極短,cpu 閒置的情況不嚴重。

## 作業系統的優化:

雖然這次作業在 I/O 上的時間並不多也並非決定執行時間的主要因素,但我認 為若能在讀入和輸出至檔案的時候也採用多執行緒的方法,在處理更大的資料 量時勢必能加快速度,很遺憾我並沒有找到方法是能做到這種事,在 I/O 時都 只能使用一個執行緒去執行,所以我認為要是作業系統也能在檔案讀寫時採用 多執行緒的方式,且不會造成寫入檔案時順序亂掉,那勢必是個很棒的優化。 雖然實測後果發現多執行緒並不依定能使執行時間加速,但我認為多執行緒的 採用是為了發揮 CPU 的最大效能,提高資源使用效率,比如你的應用程式需要 訪問網路,因為網路有延時,如果在介面執行緒訪問,那麼在網路訪問期間介 面將無法響應使用者訊息,這時就應該使用多執行緒,但我認為作業系統在各 執行緒的切換時仍需做優化,已我得測試結果為例,1個執行緒及2個執行緒 的執行時間比較上,2個執行緒還是輸1個執行緒,這就表示執行緒切換所需 的時間,並沒有比使用多執行緒節省的時間還要來的多,這是讓我覺得十分驚 訝的部分。